

Preparación de datos y clasificación de la gravedad de siniestros viales en el municipio de Envigado, Colombia

Samuel Betancur
Fernando González
Juanita

Octubre de 2026

Resumen

A partir de 89.826 registros de accidentalidad vial del municipio de Envigado (2010–2022) publicados en el portal de Datos Abiertos de Colombia, se consolidaron 43.759 siniestros únicos y se ejecutó un pipeline completo de preparación de datos: reconciliación de formatos, eliminación de variables irrelevantes y redundantes, imputación de nulos, balanceo de clases y transformaciones. Con 8 variables predictoras se abordó la clasificación binaria de la gravedad del accidente (**SOLO DAÑOS** frente a **HERIDOS**), entrenando seis modelos de clasificación con búsqueda de hiperparámetros y validación cruzada de 10 folds. El mejor modelo en la comparación fue KNN (f1 macro de 0,80); sin embargo, al verificar con datos reales y balanceo dentro de cada fold, el desempeño realista estimado es de 0,67, cifra que refleja tanto la fuga de información del sobremuestreo sintético como la proporción real de clases.

1. Objetivo

El presente informe documenta el proceso de preparación de datos y modelado de la accidentalidad vial del municipio de Envigado (Antioquia, Colombia), desarrollado en el notebook adjunto con Python (pandas, scikit-learn, imbalanced-learn, XGBoost y ydata-profiling).

El objetivo analítico es predecir la **variable objetivo** GRAVEDAD como un problema de **clasificación binaria**: **SOLO DAÑOS** frente a **HERIDOS**. La clase **MUERTOS**, con apenas el 0,3 % de los registros, se descarta por insuficiencia estadística (sección 4.7). El trabajo cubre once fases: integración de los datos, eliminación de variables irrelevantes y redundantes, descripción estadística, limpieza de atípicos y de nulos, análisis de correlaciones, balanceo, transformaciones, persistencia de los datos preparados y, finalmente, el entrenamiento de seis modelos de clasificación con hiperparametrización (GridSearchCV + validación cruzada).

2. Descripción del conjunto de datos

Fuente. Portal de Datos Abiertos de Colombia, conjunto “Accidentalidad Municipio de Envigado” (archivo CSV con corte al 29 de septiembre de 2026).

Dimensionalidad y periodo. El archivo crudo contiene **89.826 filas por 17 columnas**. No existe una correspondencia fila–accidente: cada siniestro aparece repetido una vez por cada vehículo o persona involucrada (un mismo **RADICADO** llega a repetirse hasta 24 veces). Tras consolidar por **RADICADO** quedan **43.759 siniestros únicos** (46.067 filas eran duplicados del mismo hecho), ocurridos entre el 1 de enero de 2010 y el 22 de junio de 2022.

Calidad de datos. El diagnóstico inicial evidenció:

- *Unicidad* baja en el archivo crudo: 51 % de las filas correspondían a siniestros ya registrados; resuelta con la consolidación por RADICADO.
- *Conformidad* baja en FECHA y HORA: dos formatos distintos conviven en la misma columna, señal de que el dataset proviene de dos exportaciones o sistemas de captura concatenados.
- *Complejidad* crítica en seis columnas (entre 74 % y 99,9 % de nulos) y buena en las restantes (nulos reales < 0,01 % una vez descartadas las columnas casi vacías).
- *Consistencia*: valores tipo NO REPORTADA/NO REPORTA operan como nulos disfrazados dentro de categorías válidas.
- *Exactitud* aceptable: no se detectaron valores fuera de rango en las variables numéricas codificadas.
- *Actualidad* no verificable sin metadatos del proceso de captura.

3. Descripción de las variables

La Tabla 1 resume las 17 variables originales. Seis de ellas no tienen información aprovechable como predictoras por su altísimo porcentaje de nulos; las demás se usan a lo largo del pipeline.

Tabla 1: Variables originales del conjunto de datos (porcentaje de nulos tras la consolidación por RADICADO).

Variable	Tipo	Descripción	% nulos
RADICADO	Identificador	Número único del siniestro	0
FECHA	Fecha	Fecha del accidente (dos formatos mezclados)	0
HORA	Hora	Hora del accidente (texto AM/PM y pseudo-fecha de Excel)	0
DÍA DE LA SEMANA	Categoría	Día de ocurrencia	0
CLASE DE VEHICULO	Categoría	Clase del vehículo involucrado	99,55
TIPO DE SERVICIO	Categoría	Servicio del vehículo	99,55
TIPO DE VICTIMA	Categoría	Rol de la víctima	99,90
SEXO	Categoría	Sexo de la víctima	99,90
ESTADO DE BEODEZ	Binaria	Estado de embriaguez (0/1)	0
RESULTADO DE BEODEZ	Ordinal	Nivel de embriaguez (0-3)	0
GRAVEDAD	Categoría	Variable objetivo: SOLO DAÑOS, HERIDOS, MUERTOS	0
CLASE DE ACCIDENTE	Categoría	Choque, atropello, caída, etc.	0
CAUSA	Categoría	Causa registrada (405 categorías)	0
DIRECCIÓN	Texto libre	Dirección del hecho	98,29
BARRIO	Categoría	Barrio de ocurrencia (49 categorías)	0
AREA	Categoría	Zona urbana o rural	0
Coordenadas	Texto libre	Punto geográfico (WKT)	74,14

Variable objetivo. GRAVEDAD está fuertemente desbalanceada: 79,5 % SOLO DAÑOS, 20,2 % HERIDOS y 0,3 % MUERTOS (Figura 1, derecha).




Figura 1: Izquierda: siniestros por hora del día (0–23 h). Derecha: distribución de la variable objetivo GRAVEDAD antes del balanceo.

Variables numéricas. La hora del día (extraída de HORA) tiene media 13,2 h, mediana 14 h y rango 0–23; el 50 % central de los accidentes ocurre entre las 9 y las 17 h (Figura 1, izquierda), con una ligera concentración en la tarde. **RESULTADO DE BEODEZ** es prácticamente constante en 0 (media 0,007; máximo 3): la inmensa mayoría de los conductores involucrados no presentaba embriaguez. Las variables categóricas se caracterizaron con diagramas de barras y un informe de perfilado automatizado (`ydata-profiling`) exportado como HTML.

4. Transformaciones y limpieza de datos

4.1. Integración y consolidación

La fuente única no estaba integrada de forma homogénea, por lo que se resolvieron dos problemas:

1. **Un accidente = varias filas.** Se consolidó por **RADICADO** conservando la versión más reciente de cada siniestro (`drop_duplicates(keep='last')`), pasando de 89.826 filas a 43.759 siniestros únicos.
2. **Formatos mixtos en fecha y hora.** **FECHA** mezclaba texto DD/MM/AAAA con formato ISO; se parseó con `format='mixed'` y `dayfirst=True`, y se descompuso en **AÑO** y **MES**. **HORA** mezclaba texto en español (“10:30:00 p.m.”) con una pseudo-fecha de Excel (1899-12-31T14:30:00.000, fecha “cero” al exportar solo la hora); una función dedicada reconoce ambos patrones y produce **HORA_DIA** (0–23) *sin ningún fallo de interpretación*.

4.2. Eliminación de variables irrelevantes y redundantes

Se eliminaron 7 variables **irrelevantes** (identificador o columnas sin información: **RADICADO**, **DIRECCIÓN**, **Coordenadas** y las cuatro con más del 99 % de nulos) y 2 **redundantes** (**FECHA** y **HORA**, ya descompuestas en **AÑO**, **MES** y **HORA_DIA**).

Además se redujo la **cardinalidad** de las dos variables con demasiadas categorías: **CAUSA** (405 categorías) se agrupó en las 15 causas más frecuentes (que explican el 88,6 % de los registros) más una categoría **OTRA**; **BARRIO** (49 categorías) en los 15 barrios más frecuentes (78,1 %) más **OTRO**. Con ello se evita que el paso a variables dummy genere cientos de columnas casi vacías. El dataset quedó con 10 variables, todas con información útil.

4.3. Limpieza de datos atípicos (errores de captura)

Se verificó que las variables numéricas estuvieran dentro de su rango válido: ESTADO DE BEODEZ $\in \{0, 1\}$, RESULTADO DE BEODEZ $\in \{0, 1, 2, 3\}$, HORA_DIA $\in [0, 23]$, AÑO $\in [2010, 2022]$; no se hallaron errores de rango. Los únicos errores detectados fueron 5 registros (0,011 %) con el valor NO REPORTADA/NO REPORTA en CLASE DE ACCIDENTE (1) y AREA (4): datos faltantes disfrazados de categoría, que se convirtieron a nulos explícitos.

4.4. Imputación de nulos

Ningún registro acumulaba múltiples nulos y las columnas con nulos masivos ya se habían eliminado, así que las dos columnas afectadas se imputaron por la **moda** con **SimpleImputer**: CHOQUE para clase de accidente, URBANA para área (y de forma preventiva Otra-Conductor y LAS VEGAS para causa y barrio agrupados). Tras la imputación el dataset tiene **0 nulos**.

4.5. Correlaciones: redundancias

Codificando las categóricas como dummies (solo para el análisis) y aplicando el umbral $|r| > 0,8$ se identificaron tres pares (Figura 2):

- RESULTADO DE BEODEZ vs. ESTADO DE BEODEZ ($r = 0,899$): redundancia real, pues el resultado ya contiene al estado como caso particular. Se eliminó ESTADO DE BEODEZ, conservando la variable más informativa.
- AREA_URBANA vs. BARRIO_VEREDA PALMAS ($r = -0,871$): coincidencia esperada por definición geográfica (una vereda es zona rural por definición), no una redundancia de AREA; no se tomó acción.
- GRAVEDAD_HERIDOS vs. GRAVEDAD_SOLO DAÑOS ($r = -0,990$): complementariedad matemática entre dummies del propio objetivo; no se tomó acción.




Figura 2: Matriz de correlaciones del dataset codificado (variables dummy).

4.6. Correlaciones: irrelevancia frente al objetivo

Se calculó la correlación máxima absoluta de cada variable (agrupando sus dummies) frente a las dummies del objetivo (Tabla 2). CLASE DE ACCIDENTE (0,59) y CAUSA_AGRUPADA (0,22) son las variables con mayor señal. De las de señal mínima, solo se eliminó AÑO: además de su correlación de 0,043, incluir el año exacto arriesga sobreajustar el modelo a los años observados y perjudicar la generalización a años futuros. Se conservaron HORA_DIA, DÍA DE LA SEMANA y MES pese a su baja correlación lineal, porque son variables *cíclicas* (la hora 23 está “cerca” de la 0) y el coeficiente de Pearson subestima ese tipo de relaciones no monótonas.

Tabla 2: Correlación máxima absoluta de cada variable frente al objetivo GRAVEDAD.

Variable	Máx. $ r $
CLASE DE ACCIDENTE	0,590
CAUSA_AGRUPADA	0,217
BARRIO_AGRUPADO	0,050
ESTADO DE BEODEZ*	0,045
AÑO (eliminada)	0,043
DÍA DE LA SEMANA	0,039
AREA	0,038
RESULTADO DE BEODEZ	0,035
MES	0,021
HORA_DIA	0,011

*Ya eliminada por redundancia (sección 4.5).

Tras estas depuraciones quedan **8 variables predictoras finales**: DÍA DE LA SEMANA, RESULTADO DE BEODEZ, CLASE DE ACCIDENTE, AREA, MES, HORA_DIA, CAUSA_AGRUPADA y BARRIO_AGRUPADO.

4.7. Balanceo de la variable objetivo

Un modelo entrenado con la distribución original (79,5/20,2/0,3) ignoraría las clases minoritarias. Las decisiones tomadas fueron:

1. **Eliminar la clase MUERTOS** (0,3 %): no hay casos suficientes para aprender un patrón confiable y sobremuestrearla implicaría inventar casi todos sus registros. El problema pasa a ser binario: 43.616 siniestros (34.794 SOLO DAÑOS, 8.822 HERIDOS).
2. **Submuestrear SOLO DAÑOS** al 75 % de su tamaño (**RandomUnderSampler**): 26.095 registros.
3. **Sobremuestrear HERIDOS** con **SMOTENC** (variante de SMOTE que soporta variables categóricas y numéricas mezcladas) hasta 13.047 registros.

El resultado es un dataset de **39.142 registros** con proporción deliberada de **2:1** (Figura 3): no se buscó el balance perfecto 50/50 para no introducir demasiados datos sintéticos ni descartar demasiados registros reales. Las filas se mezclaron para evitar que la validación cruzada concentre los registros sintéticos en los últimos folds, y se conservó una copia de los datos reales sin balancear (**X_real/Y_real**) para la verificación final de la sección 6.




Figura 3: GRAVEDAD después del balanceo: submuestreo de SOLO DAÑOS al 75 % y sobremuestreo SMOTENC de HERIDOS hasta la proporción 2:1.

4.8. Transformaciones finales y persistencia

Dependiendo del requisito del método de aprendizaje se prepararon **dos versiones** del dataset balanceado:

- **Versión categórica** (**datos_categoricos_discretizados.xlsx**, 39142×9): discretización de HORA_DIA en franjas horarias — Madrugada (0–5), Mañana (6–11), Tarde (12–17), Noche (18–23), Figura 4 — y de RESULTADO DE BEODEZ en Negativo/Positivo. Pensada para métodos categóricos (árboles, Bayes).
- **Versión numérica** (**datos_numericos_normalizados.xlsx**, 39142×61): normalización MinMax de las numéricas al rango $[0, 1]$, variables dummy para las categóricas (60 columnas predictoras) y LabelEncoder para el objetivo (HERIDOS= 0, SOLO DAÑOS= 1). Es la versión empleada en el entrenamiento para que los seis modelos compitan sobre las mismas variables.




Figura 4: Discretización de HORA_DIA en franjas horarias (versión categórica del dataset).

5. Entrenamiento de los modelos

Sobre la versión numérica del dataset (39.142 registros, 60 predictoras, objetivo binario) se entrenaron **seis modelos**: árbol de decisión, Random Forest, XGBoost, KNN, SVM y red neuronal (MLP). En lugar de dividir en entrenamiento/prueba (70/30), cada modelo se ajustó con **GridSearchCV** usando **validación cruzada de 10 folds** y **f1 macro** como medida (adecuada para problemas con clases desbalanceadas, pues promedia el f1 de cada clase). El f1 promedio en los folds de entrenamiento (Train CV) frente al de validación (Test CV) permite revisar el sobreajuste. La Tabla 3 resume los espacios de hiperparámetros y la mejor configuración hallada por cada búsqueda.

Tabla 3: Espacios de hiperparámetros evaluados y mejor configuración por modelo (**GridSearchCV**, 10 folds, f1 macro).

Modelo	Hiperparámetros evaluados	Mejor configuración
Árbol de decisión	criterion: gini/entropy; min_samples_leaf: 2/10/50/100; max_depth: None/10/20/50	entropy, sin límite de profundidad, hojas de 10 registros
Random Forest	n_estimators: 50/100/200; criterion: gini/entropy; max_depth: None/10/20; min_samples_leaf: 2/10; max_features: sqrt	100 árboles, gini, sin límite de profundidad, hojas de 2
XGBoost	n_estimators: 100/200; max_depth: 3/6/9; learning_rate: 0,05/0,1/0,3; subsample: 0,8/1,0	200 árboles, profundidad 9, tasa 0,3, subsample 0,8
KNN	n_neighbors: 5/15/27; weights: uniform/distance	27 vecinos, peso por distancia
SVM	kernel: rbf; C: 1/10	rbf, C = 10
Red neuronal (MLP)	hidden_layer_sizes: (15,)/(64,32); activation: relu/logistic; early_stopping	relu, una capa oculta de 15 neuronas

6. Resultados de calidad de los modelos

Tabla 4: f1 macro en validación cruzada (10 folds), ordenado por desempeño en Test CV.

Modelo	f1 Train CV	f1 Test CV	Brecha
KNN	0,9607	0,8013	0,159
Random Forest	0,8551	0,7854	0,070
XGBoost	0,8982	0,7853	0,113
SVM	0,8070	0,7630	0,044
Árbol de decisión	0,8091	0,7599	0,049
Red neuronal (MLP)	0,7574	0,7565	0,001

Comparación entre modelos. La Tabla 4 y la Figura 5 muestran que el mejor modelo es **KNN** (27 vecinos, peso por distancia) con un f1 macro de 0,8013, seguido muy de cerca por Random Forest (0,7854) y XGBoost (0,7853). En cuanto al diagnóstico de ajuste:

- **Sobreajuste:** KNN presenta la mayor brecha (f1 de entrenamiento 0,96 contra 0,80 en validación). Es esperable: con `weights='distance'` cada registro de entrenamiento se predice prácticamente a sí mismo. XGBoost también muestra una brecha notable (0,113), mientras que Random Forest la controla (0,070) gracias al promedio de árboles.
- **Subajuste relativo:** la red neuronal y la SVM tienen los f1 de entrenamiento más bajos y brechas mínimas (0,001 y 0,044): generalizan de forma estable, pero con las configuraciones probadas no logran capturar todo el patrón.




Figura 5: Comparación del f1 macro en validación cruzada de los seis modelos.

Verificación con datos reales.¹ El balanceo de la sección 4.7 se aplicó *antes* de la validación cruzada, lo que hace que el f1 anterior pueda ser **optimista** por dos razones: (1) *fuga de información*, pues los registros sintéticos de HERIDOS se crean a partir de vecinos que luego caen en otros folds, y (2) *validación sobre folds artificiales* con proporción 2:1 en lugar de la proporción real cercana a 80/20, en la que el f1 macro baja de forma natural porque la clase minoritaria es escasa.

Para obtener una estimación realista, el mejor modelo se reevaluó con los datos reales (`X_real/Y_real`) mediante un Pipeline de imblearn que ejecuta el submuestreo, el sobremuestreo SMOTENC y la preparación de variables **solo dentro del fold de entrenamiento**, dejando cada fold de validación con accidentes reales en su proporción original. El resultado es:

¹Los valores corresponden a la ejecución del notebook con `random_state=42`; pueden variar levemente entre ejecuciones o entornos.

f1 con balanceo global: **0,8013** → f1 con balanceo por fold: **0,6686 ± 0,0061** (diferencia: 0,1327)

La caída combina ambos efectos. KNN es especialmente sensible a la fuga de SMOTENC: un registro sintético casi siempre tiene como vecino más cercano al registro real del que fue generado. Por ello, el valor realista a reportar del modelo en producción es **0,67**; las cifras de la Tabla 4 sirven para *comparar* modelos entre sí, no como desempeño esperado en datos reales.

7. Conclusiones

- El pipeline de preparación transformó un archivo crudo de 89.826 filas × 17 columnas —con siniestros duplicados, formatos mixtos de fecha/hora y columnas casi vacías— en un conjunto de 43.759 siniestros únicos descrito por 8 variables predictoras limpias, sin nulos y con cardinalidad controlada, del que se derivaron dos versiones persistidas (categórica discretizada y numérica normalizada).
- La mayor señal predictiva la aportan **CLASE DE ACCIDENTE** (máx. $|r| = 0,59$) y **CAUSA_AGRUPADA** (0,22); el resto de variables tiene correlación lineal mínima con la gravedad, aunque las cíclicas (hora, día de la semana, mes) se conservaron porque la correlación de Pearson subestima relaciones no monótonas.
- En la comparación con validación cruzada, KNN fue el mejor modelo (f1 macro 0,8013), seguido de Random Forest y XGBoost; los modelos más flexibles encabezan el ranking, pero también muestran mayor brecha de sobreajuste.
- La verificación con datos reales demostró que balancear antes de la validación cruzada infla la medida: el f1 realista de KNN es $0,6686 \pm 0,0061$. El protocolo correcto —balancear únicamente dentro del fold de entrenamiento— es la cifra que debe reportarse.
- El balanceo por remuestreo no es la única alternativa: árbol, Random Forest, XGBoost y SVM pueden manejar el desbalance con pesos de clase (`class_weight='balanced'` o `scale_pos_weight`) entrenando con datos reales, mientras que KNN y la red neuronal sí requieren el remuestreo. Se usó el mismo balanceo para los seis modelos con el fin de compararlos en igualdad de condiciones.